

4. אימנו מודלים שונים על 2 קבצי מידע בעזרת פייתון, האחד הוא קורפוס השירים המלא והשני הוא קובץ של ה-Balanced Sample שקיבלנו מניתוח הדיקטה על המאגר וכולל 50 שירים מכל עשור. לכל אחד מהקבצים ביצענו ניתוח בעזרת שני מודלים - יער אקראי ורגרסיה לוגיסטית.

קיבלנו תוצאות שחלקן מפתיעות וחלקן היה סביר לצפות מראש.

ראשית, עבור הדגימה ה"מאוזנת", קיבלנו דיוק של 60% עם רגרסיה לוגיסטית ו-57% עם יער רנדומלי. העשור "הקל ביותר לזיהוי" הוא בבירור 2020s, שקיבל 88% דיוק עם רגרסיה לוגיסטית ו-86% דיוק עם יער רנדומלי. העשור הקיצוני השני, 1980s, עם 62% דיוק ב-2 המודלים, ולעומתם המודלים התקשו מאוד עם עשור האמצעי, עשור ה-2000, שבשניהם לא הגיע ל-50% זיהוי (אם כי עדיין מדובר בתוצאה טובה יותר מניחוש אקראי של 33.3%). סביר להניח שהקושי בזיהוי העשור האמצעי נובע מכך שהוא דומה סגנונית ל-2 העשורים האחרים ושנים אינן פער מספיק משמעותי על מנת לזהות בבירור שינויים סגנוניים/מבניים.

התוצאות על פי פלט הקוד:

```

=== Logistic Regression Results ===
Accuracy: 0.60

```

	precision	recall	f1-score	support
1980s	0.62	0.50	0.56	10
2000s	0.43	0.67	0.52	9
2020s	0.88	0.64	0.74	11
accuracy			0.60	30
macro avg	0.64	0.60	0.60	30
weighted avg	0.66	0.60	0.61	30

```

=== Random Forest Results ===
Accuracy: 0.57

```

	precision	recall	f1-score	support
1980s	0.62	0.50	0.56	10
2000s	0.40	0.67	0.50	9
2020s	0.86	0.55	0.67	11
accuracy			0.57	30
macro avg	0.63	0.57	0.57	30
weighted avg	0.64	0.57	0.58	30

לאחר מכן ביצענו ניתוח דומה עבור קורפוס השירים המלא. הפעם ראינו עלייה בדיוק - 2 המודלים שלנו החזירו דיוק של 62%, שהם עלייה ב-2 המודלים. כמובן ניתן היה לצפות לכך כי כעת גודל ה-dataset שלנו לאימון המודלים משמעותי יותר ולכן מאפשר ללמוד תבניות בצורה טובה יותר. בניתוח זה וידאנו שהמודלים מתחשבים בגודל המחלקות, שכן לעומת הבדיקה הקודמת עם הדגימה המאוזנת שכללה 50 שירים לכל עשור, הפעם יש לנו מחלקות בגדלים שונים. הפעם מבחינת התוצאות פר עשור קיבלנו איזון גדול יותר - מצד אחד ה-2020s ירדו לסביבת 70% זיהוי נכון, אבל מצד שני קיבלנו 57% זיהוי עבור ה-2000s, עלייה של כ-14% מניתוח הדגימה המאוזנת. עם זאת התוצאות עדיין תומכות בכך שהעשור הקל ביותר לזיהוי הוא ה-2020s והקשה ביותר הוא ה-2000s.

התוצאות על פי פלט הקוד:

```
=== FULL Corpus - Logistic Regression Results ===
Accuracy: 0.62
```

	precision	recall	f1-score	support
1980s	0.60	0.60	0.60	43
2000s	0.57	0.48	0.52	42
2020s	0.69	0.83	0.75	35
accuracy			0.62	120
macro avg	0.62	0.64	0.63	120
weighted avg	0.62	0.62	0.62	120

```
=== FULL Corpus - Random Forest Results ===
Accuracy: 0.62
```

	precision	recall	f1-score	support
1980s	0.60	0.56	0.58	43
2000s	0.57	0.57	0.57	42
2020s	0.71	0.77	0.74	35
accuracy			0.62	120
macro avg	0.63	0.63	0.63	120
weighted avg	0.62	0.62	0.62	120

חשבנו איך ניתן לשפר את תוצאות המודל והחלטנו לנסות להוסיף feature נוסף - ביגרמות (n-grams בגודל 2), כלומר צמדי מילים שמופיעות ביחד. הרצנו את 2 המודלים על ה-2 datasets עם שינוי זה. עבור הסט ה"מאוזן" קיבלנו 57% דיוק ב-2 המודלים. זו ירידה קלה עבור רגרסיה לוגיסטית ועבור יער רנדומלי זו בדיוק אותה תוצאה שקיבלנו לפני.

השינוי קרה על הסט המלא - רגרסיה לוגיסטית אמנם החזירה 58%, שהם 4% פחות מבעבר, אבל קיבלנו שיפור משמעותי ביער הרנדומלי! כעת אחוזי הזיהוי שלו הם 68% - טוב בלפחות 6% מכל מודל על כל dataset שהשתמשנו בו עד כה. זאת כנראה בשל היכולת של יער רנדומלי לאתר ולאפיין יחסים מורכבים. בנוסף, עבור יער רנדומלי עם סט מלא קיבלנו אחוזי דיוק כמעט אחידים עבור כל אחת מהמחלקות - בין 67%-ל-69%, טווח קטן ויציב משמעותית מכל מה שהגענו אליו עד כה. גם עבור רגרסיה לוגיסטית הביגרמות שיפרו את הטווח לכ-12% בין אחוז הדיוק המינימלי למקסימלי, אך כמובן לא שיפרו את אחוז הדיוק הכולל שירד.

התוצאות על פי פלט הקוד:

דוגמה מאוזנת:

```
>> Logistic Regression Results:
Accuracy: 0.57
```

	precision	recall	f1-score	support
1980s	0.57	0.40	0.47	10
2000s	0.43	0.67	0.52	9
2020s	0.78	0.64	0.70	11
accuracy			0.57	30
macro avg	0.59	0.57	0.56	30
weighted avg	0.60	0.57	0.57	30

```
>> Random Forest Results:
Accuracy: 0.57
```

	precision	recall	f1-score	support
1980s	0.56	0.50	0.53	10
2000s	0.43	0.67	0.52	9
2020s	0.86	0.55	0.67	11
accuracy			0.57	30
macro avg	0.61	0.57	0.57	30
weighted avg	0.63	0.57	0.58	30

סט מלא:

```
>> Logistic Regression Results:
Accuracy: 0.58
```

	precision	recall	f1-score	support
1980s	0.55	0.60	0.58	43
2000s	0.53	0.40	0.46	42
2020s	0.66	0.77	0.71	35
accuracy			0.58	120
macro avg	0.58	0.59	0.58	120
weighted avg	0.58	0.58	0.58	120

```
>> Random Forest Results:
Accuracy: 0.68
```

	precision	recall	f1-score	support
1980s	0.67	0.70	0.68	43
2000s	0.69	0.60	0.64	42
2020s	0.69	0.77	0.73	35
accuracy			0.68	120
macro avg	0.68	0.69	0.68	120
weighted avg	0.68	0.68	0.68	120